



**UC** | Chile



**UC** | Chile

## **Algebra Lineal Aplicada para Ciencia de Datos**



# Clase 11. Penalización cuadrática



- 1 Motivación
- 2 Formulación del problema
- 3 Solución usando mínimos cuadrados ordinarios
- 4 Solución usando la descomposición en valores singulares
- 5 La pseudoinversa
- 6 Generalizaciones



**UC** | Chile

**Motivación**

# Motivación



Los **sistemas subdeterminados**

$$Ax = y$$

con  $y \in \mathbb{R}^m$  y  $A \in \mathbb{R}^{m \times n}$  con  $m \leq n$  de **rango completo** tienen **una infinidad de soluciones**

Por lo tanto, es necesario **seleccionar** una solución

# Motivación



La clase anterior estudiamos la **solución de mínima norma Euclidea**  $x^\star$

Esta resuelve

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|x\|_2^2 \quad \text{sujeto a} \quad Ax = y$$

y se puede representar como

$$x^\star = A^\top (AA^\top)^{-1} y$$

Por construcción,

$$Ax^\star = y$$

# Motivación



Frecuentemente el vector  $y$  representa **datos experimentales** sujetos a **perturbaciones**

En este caso, la solución de mínima norma Euclidea es el vector  $\hat{x}$  que resuelve

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|x\|_2^2 \quad \text{sujeto a} \quad Ax = y + \Delta y$$

donde  $\Delta y \in \mathbb{R}^m$  representa esta perturbación

Si  $\Delta y$  es de magnitud pequeña, ¿está  $\hat{x}$  cerca de  $x^*$ ?

## Motivación. Ejemplo

$$A = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 10^{-9} & 1 + 10^{-9} \end{bmatrix}$$

Para esta matriz se tiene

$$A^T(AA^T)^{-1} = \frac{1}{3} \begin{bmatrix} 2 + 10^9 & 10^9 \\ 1 + 2 \cdot 10^9 & 2 \cdot 10^9 \\ -1 + 2 \cdot 10^9 & 0 \end{bmatrix} = \begin{bmatrix} 2/3 & 0 \\ 1/3 & 0 \\ -1/3 & 0 \end{bmatrix} + 10^9 \begin{bmatrix} 1/3 & 1/3 \\ 2/3 & 2/3 \\ 2/3 & 0 \end{bmatrix}.$$



## Motivación. Ejemplo

Si la perturbación es

$$\Delta y = 10^{-3} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

entonces

$$\hat{x} = A^T(AA^T)^{-1}(y + \Delta y) = x^* + 10^{-3} \begin{bmatrix} 2/3 \\ 1/3 \\ -1/3 \end{bmatrix} + 10^6 \begin{bmatrix} 2/3 \\ 4/3 \\ 2/3 \end{bmatrix}.$$

**La magnitud de la perturbación en la solución es  $10^9$  veces mayor a la magnitud de la perturbación en los datos**

# Motivación



Cuando esto ocurre, decimos que el sistema es **inestable**

El ejemplo muestra **no es** un problema **numérico** sino que de la **estructura** de  $A$

Para **estabilizar** la solución al problema, estudiamos la **penalización cuadrática**



**UC** | Chile

## Formulación del problema

## Formulación del problema



Sea  $y \in \mathbb{R}^m$  y  $A \in \mathbb{R}^{m \times n}$

**No supondremos ninguna relación entre  $m$  y  $n$ :** el sistema lineal

$$Ax = y$$

puede no tener solución, tener una única solución, o una infinidad de soluciones

**Buscamos soluciones aproximadas a este sistema que sean estables bajo perturbaciones de  $y$**

## Formulación del problema



El **residuo**  $r(x) = y - Ax$  determina qué tan cerca está  $x$  de ser una solución

Buscamos un vector que encuentre un balance entre **reducir la magnitud del residuo** y **penalizar la norma del vector solución**

La **penalización cuadrática** busca un  $x^*$  que resuelva

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|r(x)\|_2^2 + \lambda \|x\|_2^2$$

donde  $\lambda > 0$  es un **parámetro de penalización** que controla este balance

## Formulación del problema



$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|y - Ax\|_2^2 + \lambda \|x\|_2^2$$

Este problema se conoce con distintos nombres

- En **estadística** se conoce como **regresión contraída** o **regresión *ridge***
- En **problemas inversos** se conoce como **regularización Tikhonov**
- En **métodos Bayesianos** este problema permite determinar el **máximo *a posteriori* (MAP)** cuando se usa un *a priori* Gaussiano y la perturbación es Gaussiana



**UC** | Chile

**Solución usando mínimos  
cuadrados ordinarios**

## Solución usando mínimos cuadrados ordinarios

Para resolver el problema, primero escribimos

$$\|r(x)\|_2^2 + \lambda\|x\|_2^2 = \left\| \begin{bmatrix} y - Ax \\ \sqrt{\lambda}x \end{bmatrix} \right\|_2^2 = \left\| \begin{bmatrix} y \\ 0 \end{bmatrix} - \begin{bmatrix} Ax \\ \sqrt{\lambda}x \end{bmatrix} \right\|_2^2 = \left\| \begin{bmatrix} y \\ 0 \end{bmatrix} - \begin{bmatrix} A \\ \sqrt{\lambda}I \end{bmatrix} x \right\|_2^2.$$

Al definir

$$\hat{y} := \begin{bmatrix} y \\ 0 \end{bmatrix} \quad y \quad \hat{A} := \begin{bmatrix} A \\ \sqrt{\lambda}I \end{bmatrix}$$

podemos reformular el problema como

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|\hat{y} - \hat{A}x\|_2^2.$$



## Solución usando mínimos cuadrados ordinarios

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|\hat{y} - \hat{A}x\|_2^2.$$

La matriz  $\hat{A}$  es de  $(m+n) \times n$  por lo que es **alta**: **siempre** tiene más filas que columnas

Además **siempre rango completo**: si existiese  $z \in \mathbb{R}^n$  tal que  $\hat{A}z = 0$  entonces

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix} = \hat{A}z = \begin{bmatrix} A \\ \sqrt{\lambda}I \end{bmatrix} z = \begin{bmatrix} Az \\ \sqrt{\lambda}z \end{bmatrix} \Rightarrow z = 0$$

## Solución usando mínimos cuadrados ordinarios

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \|\hat{y} - \hat{A}x\|_2^2.$$

Concluimos que se trata de un problema de **mínimos cuadrados ordinarios**

La **ecuación normal** es

$$\hat{A}^\top \hat{A}x = \hat{A}^\top \hat{y} \quad \Rightarrow \quad (A^\top A + \lambda I)x = A^\top y.$$

Podemos resolver el problema usando la **factorización QR** de  $\hat{A}$  si bien esto no es lo más eficiente en la práctica



**UC** | Chile

**Solución usando la  
descomposición en valores  
singulares**

## Solución usando la descomposición en valores singulares



La **descomposición en valores singulares (SVD)** nos permite resolver el problema e interpretar su solución

## Solución usando la descomposición en valores singulares

La **SVD completa** de una matriz  $A \in \mathbb{R}^{m \times n}$  de rango  $r$  es la factorización  $A = U\Sigma V^\top$  donde

- $U \in \mathbb{R}^{m \times m}$  con  $U^\top U = UU^\top = I$
- $V \in \mathbb{R}^{n \times n}$  con  $V^\top V = VV^\top = I$
- $\Sigma \in \mathbb{R}^{m \times n}$  de la forma

$$\Sigma = \begin{bmatrix} \Sigma_r & 0_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{bmatrix}$$

con  $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$  y  $\sigma_1 \geq \dots \geq \sigma_r > 0$  son los **valores singulares**

## Solución usando la descomposición en valores singulares



$$(A^{\top}A + \lambda I)x = A^{\top}y.$$

La SVD completa de  $A$  nos permite simplificar esta ecuación

Por una parte,

$$A^{\top}A = (U\Sigma V^{\top})^{\top}(U\Sigma V^{\top}) = (V\Sigma^{\top}U^{\top})(U\Sigma V^{\top}) = V\Sigma^{\top}\Sigma V^{\top}$$

de modo que, usando  $VV^{\top} = I$ , se tiene

$$A^{\top}A + \lambda I = V\Sigma^{\top}\Sigma V^{\top} + \lambda VV^{\top} = V(\Sigma^{\top}\Sigma + \lambda I)V^{\top}$$

## Solución usando la descomposición en valores singulares



$$V(\Sigma^\top \Sigma + \lambda I)V^\top x = \textcolor{red}{A}^\top y$$

Por otra parte,

$$A^\top y = (U\Sigma V^\top)^\top y = V\Sigma^\top U^\top y$$

## Solución usando la descomposición en valores singulares



$$V(\Sigma^T \Sigma + \lambda I)V^T x = V \Sigma^T U^T y$$

Ya que  $V$  es invertible, al definir la variable auxiliar  $z = V^T x$  el sistema se reduce a

$$(\Sigma^T \Sigma + \lambda I)z = \Sigma^T U^T y$$



## Solución usando la descomposición en valores singulares

$$(\Sigma^T \Sigma + \lambda I)z = \Sigma^T U^T y$$

Este sistema es **diagonal**

$$\Sigma^T \Sigma + \lambda I = \begin{bmatrix} \Sigma_r^T \Sigma_r + \lambda I_r & 0_{r \times (n-r)} \\ I_{(n-r) \times r} & \lambda I_{n-r} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 + \lambda & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_r^2 + \lambda & 0 & \dots & \vdots \\ 0 & \dots & 0 & \lambda & \dots & \vdots \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & \lambda \end{bmatrix}$$

## Solución usando la descomposición en valores singulares



$$(\Sigma^\top \Sigma + \lambda I)z = \Sigma^\top U^\top y$$

Además

$$\Sigma^\top U^\top y = \begin{bmatrix} \sigma_1 u_1 \cdot y \\ \vdots \\ \sigma_r u_r \cdot y \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

## Solución usando la descomposición en valores singulares

$$(\Sigma^\top \Sigma + \lambda I)z = \Sigma^\top U^\top y$$

Por lo tanto, el sistema tiene la forma

$$\begin{bmatrix} (\sigma_1^2 + \lambda)z_1 \\ \vdots \\ (\sigma_r^2 + \lambda)z_r \\ \lambda z_{r+1} \\ \vdots \\ \lambda z_n \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 \cdot y \\ \vdots \\ \sigma_r u_r \cdot y \\ 0 \\ \vdots \\ 0 \end{bmatrix} \Rightarrow z_i^* = \begin{cases} \frac{\sigma_i}{\sigma_i^2 + \lambda} (u_i \cdot y) & i \in \{1, \dots, r\} \\ 0 & i \in \{r+1, \dots, m\} \end{cases}$$

## Solución usando la descomposición en valores singulares

Ya que  $V^T x^* = z^*$  se tiene

$$x^* = \sum_{i=1}^n z_i^* v_i = \sum_{i=1}^r \frac{\sigma_i}{\sigma_i^2 + \lambda} (u_i \cdot y) v_i = \sum_{i=1}^r \frac{1}{\sigma_i} \frac{1}{1 + \lambda/\sigma_i^2} (u_i \cdot y) v_i$$

Esta representación muestra el efecto del valor  $\lambda$

Cuando  $\lambda$  es **pequeño** el factor  $1/\sigma_i$  predomina y genera **inestabilidad** cuando  $\sigma_i$  es muy pequeño

Cuando  $\lambda$  es **grande** el factor  $1/\sigma_i$  es atenuado cuando  $\sigma_i$  es muy pequeño, **estabilizando** la solución

## Solución usando la descomposición en valores singulares



Si definimos

$$U_r = \begin{bmatrix} u_1 & \dots & u_r \end{bmatrix} \quad \text{y} \quad V_r = \begin{bmatrix} v_1 & \dots & v_r \end{bmatrix}$$

entonces podemos representar matricialmente la solución como

$$x^* = \sum_{i=1}^r \frac{1}{\sigma_i^2 + \lambda} (\sigma_i u_i \cdot y) v_i = V_r (\Sigma_r^2 + \lambda I_r)^{-1} \Sigma_r U_r^\top y$$



**UC** | Chile

## La pseudoinversa

# La pseudoinversa



¿Qué ocurre cuando  $\lambda \rightarrow 0$ ? En tal caso,

$$x^{\star} = \sum_{i=1}^r \frac{1}{\sigma_i} (u_i \cdot y) v_i = V_r \Sigma_r^{-1} U_r^{\top} y.$$

Definimos la **pseudoinversa (de Moore-Penrose)**  $A^{+}$  como

$$A^{+} = V_r \Sigma_r^{-1} U_r.$$

Vemos que  $A^{+} \in \mathbb{R}^{n \times m}$

¿Qué propiedades tiene esta matriz?

## La pseudoinversa



Propiedad	Representación matemática
Preserva información de columnas	$A^+ A A^+ = A^+$
Inversa generalizada	$A A^+ A = A$
Simetría de $A A^+$	$(A A^+)^T = A A^+$
Simetría de $A^+ A$	$(A^+ A)^T = A^+ A$



# La pseudoinversa



Cuando  $A$  es de **rango completo** podemos relacionar la pseudoinversa con

- la solución al problema de **mínimos cuadrados ordinarios** cuando  $A$  es **alta**
- la **solución de mínima norma Euclideana** cuando  $A$  es **ancha**

# La pseudoinversa

Propiedad $A$ rango completo	Representación matemática
Pseudoinversa para $A$ alta	$A^+ = (A^T A)^{-1} A^T$
Pseudoinversa para $A$ ancha	$A^+ = A^T (A A^T)^{-1}$
Solución de mínimos cuadrados ordinarios	$x^* = A^+ y$
Solución de mínima norma Euclídeana	$x^* = A^+ y$



**UC** | Chile

## **Generalizaciones**

## Generalizaciones



En algunas aplicaciones se busca un balance entre **la magnitud del residuo** y **la magnitud de una transformación lineal del vector**

Si  $L \in \mathbb{R}^{k \times n}$  buscamos encontrar el valor mínimo de

$$\|r(x)\|_2^2 + \lambda \|Lx\|_2^2$$

## Generalizaciones



En este caso, podemos realizar la misma reducción previa al definir

$$\hat{A} := \begin{bmatrix} A \\ \sqrt{\lambda}L \end{bmatrix}$$

La matriz  $\hat{A}$  es de  $(m+k) \times n$  y será de **rango completo** cuando

$$\mathbf{nul}(L) \cap \mathbf{nul}(A) = \{0\}$$

Esto ocurre, por ejemplo, cuando  $L \in \mathbb{R}^{n \times n}$  y es invertible



**UC** | Chile